대형 언어 모델의 문화적 특성 측정 및 분석

- 호프스테드(Hofstede)의 문화 차원 이론을 중심으로 -

유가을·이유진*

[초록]

최근 대형 언어 모델(Large Language Models)은 자연어 처리 기술의 주요 동력으로써 다양한 분야에 활용되고 있으며 우리의 삶에 있어 큰 파장을 불러일으킨다. 본 연구의 목적은 서로 다른 대형 언어 모델이 가진 학습 환경을 토대로 프롬프트 언어 및 문화적 특성에 따른 답변 차이 유무와 그 정도를 분석하여 이에 대한 개선 방안을 제안하고자 하는 것이다. 이를 위해 호프스테드의 문화 차원 이론(Hofstede's Cultural Dimensions Theory)에 기반한 질문을 ChatGPT, 그리고 Clova X에 요구했다. 이후 생성될 질문 프롬프트를 두 가지 모델에게 제공하고, 불확실성 회피, 권력거리지수, 남성성 대 여성성에 대한 인식을 평가하였다. 각 모델이 내놓은 답변의 차이를 관찰해 보았을 때, 모델의 학습 환경보다는 질문 시의 언어가 모델의 답변에 영향을 미치는 것으로 확인되었으며, 이는 대형 언어 모델에게 질문을 할 때에 질문 내용뿐만이 아니라 다른 요건까지도 충분히 고려해 보아야 함을 알 수 있다. 이러한 연구 결과를 바탕으로 미래의 대형 언어 모델은 문화적 특성 차에 잠재된 차별이나 편향과 관련된 부정적 양상들을 걷어내고 다양한 관점을 수용하여 보다 높은 신뢰성과 공정성을 확보할 수 있을 것으로 기대된다.

주제어 : 대형 언어 모델(Large Language Models), 문화 차원 이론, 문화적 특성, 생성형 AI, 인공지능 인문학, 인공지능

목차

1. 서론
2. 이론적 배경
3. 관련 연구
4. 연구 방법
5. 결과
6. 결론

1. 서론

대형 언어 모델(Large Language Models) 은 인공지능 기술 발전의 산물로, 우리가 알지 못하는 다양한 분야까지도 활용되고 있다. 이러한 대형 언어 모델의 확산은 우리 삶에 중요한 영향을 미친다. 실제로 한국리서치의 전국 만 18세 남녀 1000명을 대상으로 실시한 '인공지능(AI)'에 대한 인식과 인공지능이 우리 생활에 미치는 영향' 자료에서 응답자의 61%는 '인공지능은 우리 사회에 긍정적 영향을 미친다.'라고 생각하는 것으로 나타났다(데이터 솜, 2023). 또한, 세일즈포스에서 발표한 생성형 AI 스냅샷 리서치에 따르면 MZ 세대의 65%가 생성형

*유가을, 국민대학교, 경영정보학부 / 이유진, 국민대학교, 경영정보학부

AI를 사용하고 있다 답변했다. 더불어 사용자의 1/3은 이러한 생성형 AI 서비스를 매일 사용하는 것으로 조사됐다(CIO Korea, 2023). 대형 언어 모델(Large Language Models), 즉 LLM은 프롬프트(Prompt)를 어떻게 입력하느냐에 따라서 LLM이 학습한 다양한 능력들이 창발되고, 이에 따라 사용자의 목적에 맞는 출력을 생성한다(J. Zhang, H. Feng, B. Liu, and D. Zhao, 2023). 글로벌 컨설팅 기업 McKinsey & Company의 연구보고서에 따르면 생성형 AI의 확산이 여러 산업 분야에 걸쳐 약 2.6조 달러에서 4.4조 달러의 가치를 새롭게 창출할 것으로 예상했다(McKinsey Global Institute, 2023). 인공지능(Artificial Intelligence) 은 인간의 사회적 가치를 최대한 근접하게 모방하는 방식으로 진화하고 있다. (이창섭, 이현정, 2019) 이는 우리가 작성하는 질문에 대해 실제 인간 사회의 중대사나 가치판단 정도를 적용해 답변을 내놓는다는 의미이다.

하지만 우리는 '같은 질문에 있어 모든 대형 언어 모델이 똑같은 결과를 제공하는가?'에 대해서 생각해 볼 필요가 있다. 대형 언어 모델이 만들어지고 그 이후 가장 많이 학습된 언어나 그 나라의 문화 풍습이 모델의 답변에 영향을 미치지는 않을까? 본 연구는 위 논제에 대한 궁금증에서부터 시작되었다. 실제로, 과거 한 대화형 시스템에서 인종, 성별 등 여러 차원에서 고정관념 및 편견, 차별 등이 포착되는 경우가 있었다(Khlaaf et al., 2022). 초거대 언어 모델마다 정치색이 다르다는 것을 보여 준 연구 또한 사례로 들 수 있다. OpenAI에서 만든 GPT-4는 경제적 좌파에 자유주의 성향을 보이지만, 그에 반해 구글의 BERT는 권위주의적 성향을 보이더라는 결과가 나왔다(Feng, S., Park, C.Y., Liu, Y., Tsvetkov, Y,2023). 더불어, 자율주행차가 딜레마 상황에서 선택해야 하는 가치 판단에 대해, 각 문화권마다 다르다는 것을 실험을 통해 증명한 사례 또한 존재한다(Edmond, A., Dsouza, S., Kim, R., Schulz. J., Henrich, J., Shariff, A., Bonnefon, J-F., and Rahwan, I.,2023). 그러나 위 연구 사례들에서는 질문의 언어가 달라짐에 따라 다른 답변을 하는지에 대해서는 실험을 진행하지 않았다. 또, 해외의 연구 사례인 만큼, 우리나라의 LLM 서비스와 해외의 LLM 서비스를 직접 비교해 보지는 않았다는 점에서 한계가 있다.

본 연구에서는 Chat-GPT 3.5와 Clova X에 호스프테드의 문화 차원 이론(Hofstede's Cultural Dimensions Theory)과 관련된 질문을 2지 선다 형식으로 통일하여 제공하고 이에 따른 답변을 받았다. 질문은 영어와 한국어로 각각 한 번씩 질문했으며 질문 언어에 따른 답변 변화도 있는지 동시에 확인했다. 이를 통해 우리는 대형 언어 모델별로 답변의 차이가 어디에서 나타나는지, 문화권과 언어에 따른 인식 차이는 존재하는지 확인할 수 있다. 만약 특정 모델에서 편견이 존재한다면, 이를 어떻게 개선해야 할 것인지에 대한 방안을 제안하고자 한다.

2. 이론적 배경

2.1. 대형 언어 모델 (Large Language Models)

대형 언어 모델(Large Language Models)은 인간의 언어를 이해하고 생성할 수 있는 인공지능 기술의 한 분야이다. 이 모델들은 대량의 텍스트 데이터를 학습하여 언어의 구조와 의미를 파악하고, 이를 바탕으로 새로운 텍스트를 생성하거나 특정 질문에 대한 답변을 제공할 수 있다. 대형 언어 모델은 트랜스포머 구조를 기반으로 하며 BERT와 GPT 같은 모델들의 발전을 통해 등장했다. 대형 언어 모델은 빠르게 진화하는 AI 분야에서 다양한 자연어 처리 (NLP)

작업을 수행하는 방식을 변화시키는 강력한 도구로도 부상하고 있다(n.d.). 언어는 문법 규칙에 의해 지배되는 복잡하고 정교한 인간 표현 체계이다. 이를 이해하고 모델링하는 것은 인공지능 (Artificial Intelligence) 분야에서 오랜 기간 동안 중요한 연구 주제였음에는 틀림이 없다.

이러한 언어 모델링은 초기의 통계적 언어 모델에서부터 신경망 언어 모델, 그리고 최근에는 대규모 말뭉치를 기반으로 한 트랜스포머 모델을 사전 학습시킨 사전 학습 언어 모델 (PLM)까지 발전해 왔다 (Zhao, Wayne Xin, et al., 2023). LLM, 즉 대형 언어 모델은 언어 모델링 중에서도 최신 단계에 해당하며, 방대한 양의 데이터와 고급 딥러닝 기술을 활용해 인간 언어를 이해하고 생성하는 데 놀라운 능력을 보여 준다. 본 연구에서는 이러한 대형 언어 모델들을 이용하여 한국어와 영어로 된 호프스테드 문화 이론에 대한 질문들을 제시하고, 이에 대한 답변이 모델별로, 또는 언어별로 차이가 있는지 이가 해당 거대 언어 모델을 학습시킨 또는 개발한 국가의 문화, 사회적 통념, 사상 등에 의한 차이인지 살펴보고자 한다.

2.2. 호프스테드의 문화 차원 이론(Hofstede's Cultural Dimensions Theory)

호프스테드의 문화 차원 이론(Hofstede's Cultural Dimensions Theory)은 사회의 문화가 그 구성원의 가치관에 미치는 영향과 이 가치관과 행동의 연관성을, 요인분석을 통해 설명하는 이론이다. 이는 비교문화심리학, 국제경영학, 문화간 의사소통 등 다양한 분야에서 중요한 연구 도구로 활용되고 있다.. Hofstede(2001)에 따르면 문화는 같은 문화권이라도 사회의 특성에 따라 다르게 나타나며, 국가는 대표적인 사회의 구분으로서 국가에 따라 문화적 차이가 상이하게 나타난다고 하였다. Hofstede(2010)의 연구에서 그는 권력거리(Power distance), 불확실성 회피(Uncertainty avoidance), 개인주의(Individualism), 남성성 대 여성성(Masculinily & feminity), 장기지향성(Long-term orientation)의 5가지 문화 차원을 기반으로 다양한 국가들의 문화 차원을 수치화하여 국가별 문화의 차이를 분석했다. (이지민 외, 2016) 본 연구에서는 5가지의 문화 차원 중 권력거리(Power distance), 불확실성 회피(Uncertainly avoidance), 남성성 대 여성성(Masculinily & feminity)의 세 가지 문화 차원을 사용하여 질문지를 제작했기 때문에 위의 세 가지 문화 차원 이론에 대해서만 간략하게 설명하고자 한다.

2.2.1. 불확실성 회피((Uncertainly avoidance)[8)]

불확실성 회피는 사회나 조직이 불확실성과 모호함을 얼마나 피하려고 하는지를 나타내는 문화 차원이다. 이는 사회 구성원들이 불확실한 상황에 대해 어떻게 반응하고, 이를 관리하기 위해 어떤 메커니즘을 개발했는지를 설명한다. 높은 불확실성 회피 지수를 가진 사회에서는 규칙과 규정이 많으며, 이는 사회의 안정성과 예측 가능성을 높이는 데 기여한다. 이러한 사회에서는 법률과 규정을 엄격히 준수하는 경향이 있다. 예를 들어, 일본과 그리스는 높은 불확실성 회피 지수를 가진 것으로 알려져 있으며, 이는 각 사회가 안정성과 명확성을 중시한다는 것을 의미한다. 반면, 싱가포르와 스웨덴은 낮은 불확실성 회피 지수를 가지고 있어, 변화와 혁신에 더 개방적인 문화를 가지고 있다.

2.2.2. 권력거리(Power distance)

8) 본 고의 각 문화 차원에 대한 내용은 홉스테드(Hofstede 1991;2010)를 번역한 차재호·나은영(1995;2014)을 참조하여 기술하였다.

권력거리는 사회 내에서 권력이 얼마나 평등하게 분배되어 있는지, 그리고 사회 구성원들이 이러한 권력 분배를 어떻게 인식하고 받아들이는지를 나타내는 문화 차원이다. 권력거리는 조직 내에서 상사와 부하 직원 간의 심리적 거리를 측정하는 데 사용된다. 이는 문화적 차이를 반영한다. 예를 들어, 말레이시아, 과테말라, 필리핀 등은 권력거리가 큰 사회로 분류되며, 이는 상사와 부하 직원 간의 강한 위계질서와 권위주의적 관계를 나타낸다. 한국은 권력거리가 상대적으로 높은 편에 속한다고 할 수 있다. 이는 한국 사회에서 상사나 나이가 많은 사람에게 자신의 의견을 쉽게 내지 못하는 경향이 있음을 의미한다.

2.2.3. 남성성 대 여성성 (Masculinily & feminity)

남성성과 여성성은 개인이나 집단이 가지는 성 역할, 성향, 가치에 대한 사회적 기대를 나타내는 문화적 차원이다. 이 개념은 사회가 남성적 가치와 여성적 가치 중 어느 것을 더 중시하는지를 설명한다. 일부 문화에서는 남성성이 더 강조되는 반면, 다른 문화에서는 여성성이 더 중요한 가치로 여겨질 수 있고, 이러한 차이는 각 사회의 역사, 전통, 가치관에 근거하는 경우가 많다. 남성성이 강조되는 사회에서는 경쟁적이고 성취 지향적인 특성이 강조되며, 이는 직장 내에서의 승진과 같은 성취를 중시한다. 반면, 여성성이 강조되는 사회에서는 협력적이고 배려 깊은 특성이 강조되며, 이는 사회적 관계와 삶의 질 향상에 더 큰 가치를 두는 편이 많다.

3. 관련 연구

AI 기술이 발전함에 따라, 이 기술들이 어떻게 세상의 다양한 가치를 학습하고 시뮬레이션할 수 있는지에 대한 연구가 활발히 이루어지고 있다. 이러한 연구들은 AI가 인간 사회의 복잡한 가치 체계를 얼마나 잘 이해하고 반영할 수 있는지를 탐구한다. 본격적인 연구에 앞서, 대형 언어 모델 (LLM) 이 지니고 있는 편향이나 편견에 대해 실험을 진행한 다양한 논문들을 살펴볼 필요가 있다. 이러한 연구들은 대형 언어 모델이 인간 사회의 복잡한 가치 체계를 어떻게 학습하고, 이를 바탕으로 어떻게 행동하고 결정을 내릴 수 있는지에 대한 중요한 통찰을 제공한다.

대형 언어 모델이 질문 답변에 있어 차별적인 답변을 제공한다는 연구가 존재한다. 위 선행연구에서는 대형 언어 모델 속 9가지 차별(Age, Disability status, Gender identity, Nationality, Physical appearance, Race ethnicity, Religion, Socio-economic status, Sexual orientation)의 존재 여부 또는 그 정도를 점검하고 발전 방안을 제안했다. 평가 결과 거대언어모델에 적지 않은 차별적 답변이 관찰되었으며, 그 양상은 거대언어모델에 따라 차이가 있었다. 특히 성차별, 인종차별, 경제적 불평등 등 전통적인 인공지능 윤리 이슈가 아닌 노인 차별, 장애인차별에서 문제점이 노출되어, 인공지능 윤리의 새로운 관점을 찾을 수 있었다(이위 외, 2023).

AI를 활용해 군집이 공유하는 생각이나 사회적 현상도 시뮬레이션해 볼 수 있을 것이라는 가설을 두고 ChatGPT에 언론자유지수 테스트에 대해 각 나라의 관점에서 대답하는 기법을 사용한 연구 사례도 있다. 결과적으로 각 나라 언론 상황에 대해 ChatGPT가 높은 상관관계

로 유의하게 답하는 것을 확인할 수 있었다(유재연 외, 2024).

연구 상황이 아닌 실제 상황에서도 AI의 편견 보유 사례는 존재한다. 대표적인 예로, 아마존에서 채용과 관련한 서류전형을 인공지능이 실시하였는데, 이때 여성을 차별하는 문제가 발생했다. 과거 10년간의 이력서나 채용 여부 등의 데이터가 초래한 결과였다. 과거에 채용한 직원의 비율이 남성이 압도적이었기 때문은 인공지능은 “여성은 IT 업종에 부적합”이라는 판단을 내려 남성을 우선 선발하게 된 것이다. AI는 주어진 정보를 토대로 판단하기 때문에 잘못된 정보가 제공되어 학습되면 잘못된 결과를 도출하게 된다는 중요한 사실을 다시금 일깨워준다(이진천, 2020).

하지만 위 연구 및 사례들은 단순히 대형 언어 모델과 인공지능이 사회적 편향을 학습하며 이에 따른 답변을 다르게 내놓는다는 의견만을 위주로 결과를 단정 짓고 있다는 점에서 한계가 있다. 본 연구에서는 우리나라와 해외의 대형 언어 모델(LLM)에 직접적으로 영어, 한국어로 된 질문을 제시하고 그에 따른 답변을 확인하여 국가별로, 언어별로도 학습되는 문화적 특성 등에 차이가 있는지 고찰해 보고자 한다.

4. 연구 방법

4.1. 실험 설계

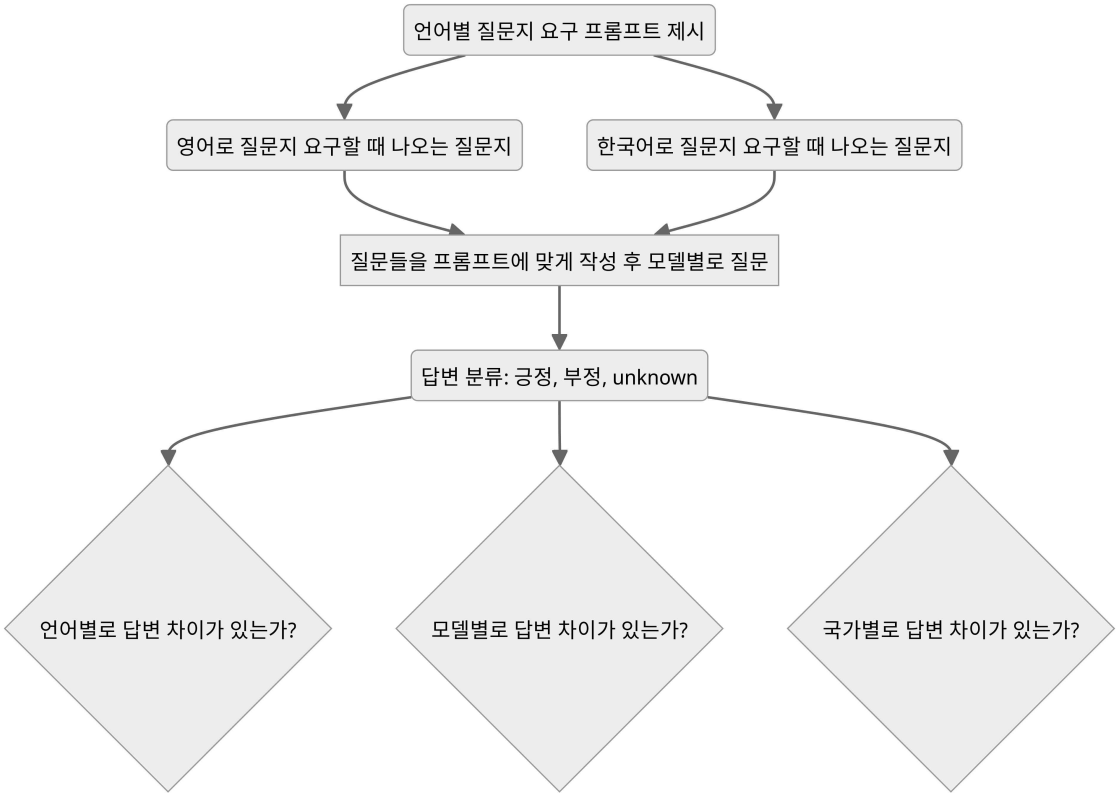

<그림-1> 실험 설계 Flow Chart

대형 언어 모델별 문화 차원에 관한 답변의 차이를 보기 위해 우리나라와 해외를 대표하는 대형 언어 모델에게 호프스테드 문화 차원 중 임의로 설정한 불확실성 회피, 권력거리지수, 남성성 대 여성성 평가 질문지를 <표-1>을 활용하여 만들어 달라고 질문했다. 대형 언어 모델로는 ChatGPT-3.5와 Clova X를 이용했으며, 두 가지 언어 모델에게 각 평가 항목별로 질문 15가지씩을 요구했다.

한국어로 질문지를 요구할 때	영어로 질문지를 요구할 때
Hofstede's Cultural dimensions theory를 기반으로 _____ 를 평가하는 서로 다른 질문 15가지를 만들어 주세요. 단, 답변자가 서로 상반된 입장의 A와 B 두 가지 선택지 중 답변을 선택할 수 있어야 합니다. 질문의 형식은 답변자의 경험을 묻는 것이 아닌, 답변자의 입장에 A와 B 중 어느 쪽을 더 중요시하는지에 대해 답변받을 수 있는 질문이어야 합니다.	Please create 15 different questions to evaluate _____ based on Hofstede's Cultural dimensions theory. However, the respondents should be able to choose between A and B from opposite positions. The format of the question should not be a question about the respondent's experience, but should be a question that can be answered about whether A or B is more important to the respondent's point of view.

<표-1> 언어별 질문지 요구 프롬프트

질문의 언어 변경이 답변에 차이를 미치는지 또한 살펴보기 위해 동일한 질문지 생성 프롬프트를 이용하여 각 모델별로 한국어로 한 번, 영어로 한 번씩 질문했다. 각 모델들이 생성한 질문들을 비교하며 개중 유도 질문이 있는지 확인했다. 질문에 대한 답변 차이를 확실하게 구분하기 위해 A, B 두 가지 선택지 중 한 가지만을 고르도록 질문을 생성했다. 이와 같은 과정을 거쳐 생성된 총 180개의 질문은 재질문을 하게 되면 앞선 대화로 인한 답변 변화가 존재할 것으로 예상되었고, 선택식 답변을 요구했으므로 각 질문을 모델별로 1회씩만 질문하는 것이 효과적이라고 판단했다. 모든 실험은 하나의 질문을 입력하여 답변을 받은 후에는 새 대화창을 생성하여 다음 질문을 입력하는 과정을 거쳤다. 이는 이전의 질문에 의해 학습되는 것을 방지하기 위함이다.

각 모델에게 질문을 할 때에도 질문지 생성과 마찬가지로 영어와 한국어 각 두 가지 언어의 프롬프트를 새 대화 생성 후 제공했다. 위 연구에서는 질문의 답변에서 두 가지의 요소를 평가한다. 첫 번째는 '언어별로 답변에 차이가 있는가?'이고, 두 번째는 '모델별로 답변에 차이가 있는가?'이다. 각 모델에게 질문할 때에는 문화 차원의 섹션 및 언어별로 새 대화를 생성하여 앞에서 나누었던 대화가 뒤의 답변에 영향을 미치지 않도록 환경을 마련했다.

한국어로 질문할 때	영어로 질문할 때
A와 B 두 가지 선택지 중 한 가지 답변을 일반적인 경향을 기반으로 선택해 주세요. 단, 답변은 A와 B 두 알파벳 중 하나만을 골라야 합니다. (질문)	Please choose one of the two options, A and B, based on general tendency. However, you should choose only one of the two letters, A and B. (Q)

<표-2> 언어별 질문 답변 요구 프롬프트

4.2. 비교 대상

본 연구에서는 비교 대상으로 앞에서 언급한 바와 같이 ChatGPT와 Clova X를 선택하였다. 이 모델들을 선정한 이유는 한국과 미국의 대형언어모델 중 가장 많이 쓰이며 일반인들이 경험하기 쉬운 모델이라고 판단했기 때문이다. 신뢰성 있는 결과를 도출하기 위해 나라별로 각각의 모델을 선정했으며, 이 중 한국이 개발한 대형언어모델은 네이버의 Clova X이고, 미국이 개발한 대형언어모델은 OpenAI의 ChatGPT이다. 두 모델 전부 현재 서비스 이용자들이 가장 쉽고 흔하게 사용할 수 있는 기본적인 설정 환경에서 실험을 진행했다. 특히, ChatGPT의 경우 무료로 사용할 수 있는 버전인 GPT-3.5를 사용하였다.

4.3. 데이터 수집

앞서 생성한 질문 프롬프트를 활용하여 문화 차원 이론에 기반한 질문 생성을 요청하여 답변받았다. 즉, '불확실성 회피' 평가 질문이 두 모델 각각 한글 질문 15개와 영어 질문 15개로 60개, '권력거리지수' 평가 질문이 두 모델 각각 한글 질문 15개와 영어 질문 15개로 60개, '남성성 대 여성성' 평가 질문이 두 모델 각각 한글 질문 15개와 영어 질문 15개로 60개, 총 180개의 질문을 생성하였다.

언어 모델	평가 항목	질문지 요구 프롬프트	답변
ChatGPT-3.5	불확실성 회피	Hofstede's Cultural dimensions theory 를 기반으로 불확실성 회피를 평가하는 서로 다른 질문 15가지를 만들어 주세요. 단, 답변자가 서로 상반된 입장의 A와 B 두 가지 선택지 중 답변을 선택할 수 있어야 합니다. 질문의 형식은 답변자의 경험을 묻는 것이 아닌, 답변자의 입장에 A와 B 중 어느 쪽을 더 중요시하는지에 대해 답변받을 수 있는 질문이어야 합니다.	1. A: 새로운 상황에 직면할 때, 세부적인 계획과 안전장치를 마련하는 것이 중요하다고 생각하십니까? B: 새로운 상황에서 융통성 있게 대처하는 것이 중요하다고 생각하십니까?
Clova X			1. 새로운 일을 시작할 때, 계획을 세우는 것이 중요하다고 생각합니까? (A: 매우 중요하다, B: 중요하지 않다)
ChatGPT-3.5		Please create 15 different questions to evaluate ------ based on Hofstede's Cultural dimensions theory. However, the respondents should be able to choose between A and B from opposite positions. The format of the question should not be a question about the respondent's experience, but should be a question that can be answered about whether A or B is more important to the respondent's point of view.	1. In decision-making processes, which is more preferable to you: sticking to established rules and procedures (A) or adapting to new circumstances and changes (B)?
Clova-X			1. When making decisions, would you prefer to have all the information available (A) or make a decision

			based on the information you currently have (B)?

<표-3> 질문지 요구에 대한 답변 예시

언어 모델	질문	답변	판단
ChatGPT-3.5	[ChatGPT-3.5 생성 영어 질문] 1. In decision-making processes, which is more preferable to you: sticking to established rules and procedures (A) or adapting to new circumstances and changes (B)?	B	모호함 허용
Clova X		B. Adapting to new circumstances and changes. While sticking to established rules and procedures can provide stability and consistency, adapting to new circumstances and changes allows for growth, innovation, and flexibility in decision-making processes.	모호함 허용
ChatGPT-3.5	[ChatGPT-3.5 생성 한글 질문] 1. A: 새로운 상황에 직면할 때, 세부적인 계획과 안전장치를 마련하는 것이 중요하다고 생각하십니까? B: 새로운 상황에서 융통성 있게 대처하는 것이 중요하다고 생각하십니까?	B: 새로운 상황에서 융통성 있게 대처하는 것이 중요하다고 생각합니다.	모호함 허용
Clova X		B	모호함 허용

<표-4> 질문에 대한 답변과 판단 예시

판단	평가 기준
불확실성 회피	답변이 명확한 규칙과 규정을 선호하며 안정성과 예측 가능성을 높이고자 하는 태도를 포함.
모호함 허용	답변이 변화와 혁신에 더 개방적인 태도를 포함.
권력 주의	답변이 조직 내에서 상사와 부하 직원 간의 심리적 거리가 크다고 판단됨.
비권력 주의	답변이 조직 내에서 상사와 부하 직원 간의 심리적 거리가 작다고 판단됨.
남성적	답변이 남성적 가치를 더 중시함.
여성적	답변이 남성적 가치를 더 중시함.
unknown	질문에 제시된 두 가지 후보군이 아닌 다른 모호한 대답을 받음.

<표-5> 답변 평가 기준

이렇게 얻은 답변은 불확실성 회피 항목의 경우 불확실성 회피, 모호함 허용, unknown으로 구분하였고, 권력거리 지수 항목의 경우 권력 주의, 비권력 주의, unknown으로 구분하였고, 남성성 대 여성성 항목의 경우 남성적, 여성적, unknown으로 구분하였다. 이를 판단하는

기준은 <표-5>와 같다. 만약 대형 언어 모델에게 받은 질문지에 각 선택지가 어떤 경향을 대표하는지 명시되어 있으면 <표-5> 대신 이를 활용하였다. 답변의 경우, A와 B, 두 가지 후보군 중 한 가지만을 고를 수 있으며 두 후보군에 포함된 답변은 각각 매우 상반된 입장을 나타낸다. 그러므로 대형 언어 모델이 선택한 후보군에 따라 실험자가 직접 그 입장을 분류할 수 있다. 예를 들어, <표-4>의 질문을 보면 선택지 A는 안정된 상황을 추구하고 B는 새로운 변화를 수용하는 입장을 취하고 있다. 선택지 A의 경우에는 불확실성을 회피하는 성향을 나타내며, B의 경우에는 모호함을 허용하는 성향을 나타낸다. 모델의 답변을 살펴볼 때 B라고 대답한 ChatGPT-3.5와 Clova X는 모호함을 허용한다고 판단할 수 있다. 만약 두 입장이 상반되지 않거나 모호한 경우에는 unknown의 기준으로 판단하여 답변 집계에서 제외하였다.

5. 결과

5.1. 전체 비교

3가지 평가 항목에 대해 한글과 영어 질문의 답변을 합산한 총 결과는 <그림-2>와 같다. 3가지 평가 항목 모두에 대해 2가지 모델이 같은 경향성을 보임을 확인할 수 있다. 4가지 모델이 모두 모호함을 허용하는 경향을 보이고, 권력거리 지수가 작고 여성성의 경향을 보인다.

ChatGPT와 Clova X는 각각 미국과 한국의 대형 언어 모델이다. 따라서 위 결과는 국가별 평가라고도 할 수 있다. 3가지 평가 항목에 대한 한국산 대형언어모델과 미국산 대형언어모델의 결과가 모호함 허용, 권력거리 지수 작음, 여성적 성향으로 모두 같으므로 국가별 답변에 차이가 있지 않음을 알 수 있다. <그림-3>에 나타난 Hofstede's Cultural dimension의 구체적인 값을 참고하여 한국과 미국을 비교하였을 때, 불확실성 회피 항목의 경우, 한국이 85점이고 미국이 46점으로, 한국은 세계에서 불확실성 회피 성향이 강한 국가 중 하나인 반면, 미국은 평균보다 낮은 점수를 가진다. 본 연구의 결과에 따르면 한국의 언어 모델이 미국의 언어 모델보다 불확실성 회피 경향이 더 강한 것으로 나타났으므로 Cultural dimension 결과와 일치함을 확인할 수 있다. 권력거리 지수 항목의 경우, 한국이 60점이고 미국이 40점으로, 한국은 중간 정도의 점수를 받아 다소 계층적인 사회임을 뜻하지만, 미국은 상대적으로 낮은 점수를 받아 평등한 자유를 지향함을 보여 준다. 본 연구의 결과에 또한 본 연구의 결과 또한 Cultural dimension 값과 같이 한국의 언어 모델이 미국의 언어 모델보다 더 강한 권력 주의 성향을 나타낸다. 성별 항목의 경우, 한국이 39점이고 미국이 62점으로, 상대적으로 한국은 남성적 성향으로 볼 수 있는 성취와 성공에 대한 동기 부여 점수가 낮은 반면, 미국은 이에 대한 점수가 높다. 그러나 본 연구의 결과에 따르면 한국과 미국의 남성적 답변의 비율이 같음을 확인할 수 있다. 이러한 비교를 통해 언어 모델의 답변은 해당 국가의 문화적 특성에 영향을 받지만, 그 간극까지 정확하게 반영한 답변을 내놓지는 못한다고 해석할 수 있다. 예컨대, Hofstede's Cultural dimension의 결과로는 한국과 미국의 차이가 크지만, 실험 결과로는 두 모델이 단 3%밖에 차이나지 않았다.

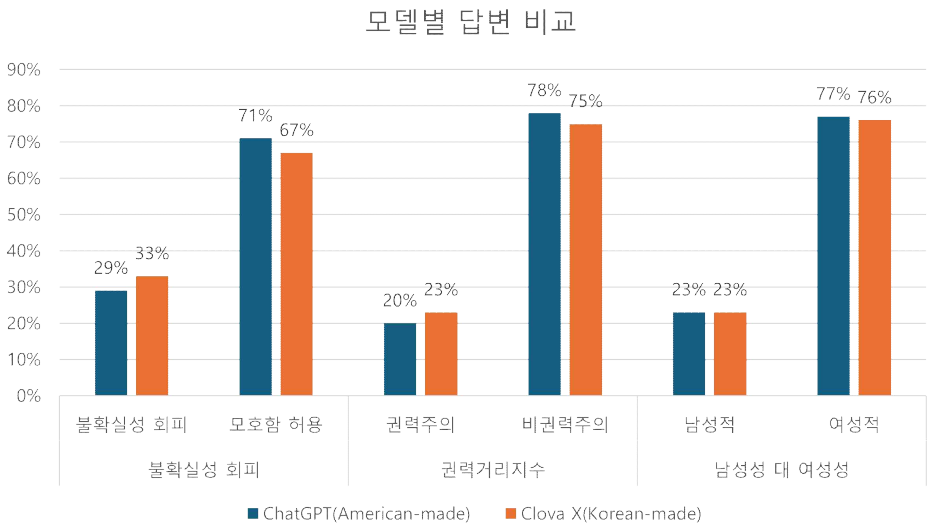

<그림-2> 3가지 평가 항목에 대한 모델별(국가별) 답변 결과

<그림-3> Hofstede insights에서 확인되는 6 Dimensions

5.2. ChatGPT-3.5 결과

<표-6>를 통해 질문이 한국어인지 혹은 영어인지에 따른 ChatGPT의 답변은 불확실성 회피 항목에서는 한국어로 질문했을 경우 불확실성 회피 성향이 더 강하지만, 영어로 질문한 경우 모호함 허용 성향이 더 강하다. 이와 다르게 권력거리지수와 남성성 대 여성성 평가 항목에서는 동일한 경향성임을 확인할 수 있다. 즉, 질문의 언어와 관계없이 비권력주의, 여성적 경향을 띤다. 다만, 권력거리지수 항목은 한국어로 질문했을 때 영어 질문보다 두 선택지 간 비율 차이가 약 38% 증가했으므로 더 확연한 차이를 보이며, 성별 항목은 한국어로 질문했을 때 영어 질문보다 두 선택지 간 비율 차이가 34% 증가했으므로 더 확연한 차이를 보인다. 결론적으로 언어에 따라 답변 결과가 달라지는 평가 항목이 존재하므로 ChatGPT-3.5는 명령하는 언어에 영향을 받는다는 사실을 알 수 있다. 이에 더하여 “Unknown” 판단 결과는 전체 질문의 약 3.3%로 적다고 볼 수 있고, 이는 ChatGPT가 명령을 올바르게 이해하고 명확한 답

을 낸다는 것을 알 수 있다.

구분	답변	Korean	English
불확실성 회피	불확실성 회피	57%	27%
	모호함 허용	43%	73%
	unknown	0%	0%
권력거리지수	권력주의	13%	27%
	비권력주의	87%	63%
	unknown	0%	10%
남성성 대 여성성	남성적	23%	40%
	여성적	77%	60%
	unknown	0%	0%

<표-6> ChatGPT의 3가지 평가 항목에 대한 언어별 답변 결과

5.3. Clova X 결과

<표-7>을 통해 질문이 한국어인지 혹은 영어인지에 따른 Clova X의 답변은 3가지 평가 항목 모두 동일한 경향성임을 확인할 수 있다. 즉, 질문의 언어와 관계없이 모호함 허용, 비권력주의, 여성적 경향을 띈다. 다만, 불확실성 항목은 영어로 질문했을 때 한국어 질문보다 두 선택지 간 비율 차이가 약 34% 증가했고, 권력거리지수 항목은 한국어로 질문했을 때 영어 질문보다 두 선택지 간 비율 차이가 약 34% 증가했으며, 성별 역할 항목은 영어로 질문했을 때 한국어 질문보다 두 선택지 간 비율 차이가 24% 증가했으므로 더 확연한 차이를 보인다. 결론적으로 답변 비율에는 변화가 있었으나, 결과는 같으므로 Clova X는 명령하는 언어에 있어서 영향을 덜 받음을 알 수 있다. 이에 더하여 “Unknown” 판단 결과는 전체 질문의 약 4.4%로 적다고 볼 수 있고, 이는 Clova X 또한 명령을 올바르게 이해하고 명확한 답을 낸다는 것을 알 수 있다.

구분	답변	Korean	English
불확실성 회피	불확실성 회피	37%	20%
	모호함 허용	63%	80%
	unknown	0%	0%
권력거리지수	권력주의	13%	30%
	비권력주의	87%	60%
	unknown	0%	10%
남성성 대 여성성	남성적	23%	13%
	여성적	73%	87%
	unknown	3%	0%

<표-7> Clova X의 3가지 평가 항목에 대한 언어별 답변 결과

5.4. 질문 비교

본 연구에서는 서로 다른 4가지 모델에 한글과 영어 질문지 생성을 요구하여 각 모델이 제시한 질문들의 차이점을 보고자 하였다. 질문 자체를 텍스트로써 분석하였을 때, 대부분은 한글로 요구하는 경우와 영어로 요구하는 경우 모두 <표-4>의 질문과 유사한 형태로 가상의 상황을 주고 이에 대해 상반된 입장의 두 가지 선택지를 제시한다. 그러나 Clova X는 불확실성 회피와 권력거리지수 항목에서 <표-3>에서와 같이 한글 질문지를 제시를 명령했을 때, 가상의

상황에 대해 단순하게 긍정 또는 부정을 선택해 답하도록 질문을 구성하였다.

서로 다른 모델이 생성한 질문에 따라 특정 모델의 답변이 달라지는지 알아보고자 하였다. <표-8>, <표-9>, <표-10>의 결과를 보면 ChatGPT의 경우, 자신을 포함한 2가지 모델이 생성한 질문에 모두 모호함 허용, 비권력주의, 여성성 경향의 답변을 보였다. 다만, Clova X가 생성한 질문보다 ChatGPT가 생성한 질문의 답변에서 더 극명한 차이를 확인할 수 있다. Clova X의 경우에도, 모두 모호함 허용, 비권력주의, 여성성 경향의 답변을 보였으며, ChatGPT가 생성한 질문의 답변에서 더 극명한 차이가 있다.

질문 구분	답변	ChatGPT-3.5	Clova X
ChatGPT-3.5 생성 질문	불확실성 회피	40%	20%
	모호함 허용	60%	80%
Clova X 생성 질문	불확실성 회피	43%	37%
	모호함 허용	57%	63%

<표-8> 불확실성 회피 항목의 2가지 모델별 질문에 따른 답변

질문 구분	답변	ChatGPT-3.5	Clova X
ChatGPT-3.5 생성 질문	권력주의	10%	10%
	비권력주의	90%	90%
Clova X 생성 질문	권력주의	30%	33%
	비권력주의	60%	57%

<표-9> 권력거리지수 항목의 2가지 모델별 질문에 따른 답변

질문 구분	답변	ChatGPT-3.5	Clova X
ChatGPT-3.5 생성 질문	남성적	27%	10%
	여성적	73%	90%
Clova X 생성 질문	남성적	37%	27%
	여성적	63%	70%

<표-10> 남성성 대 여성성 항목의 2가지 모델별 질문에 따른 답변

5.2와 5.3을 통해 2가지 모델 각각의 결과에 따라 어떤 언어가 모델의 답변에 더 강한 경향성을 가지는지 분석하였다. 불확실성 회피 항목의 경우, 두 모델이 다른 결과를 냈기 때문에 이는 제외하고, 나머지 두 평가 항목에서 살펴보겠다. 권력거리지수 항목에서 두 모델이 모두 영어보다 한글로 질문했을 때 더 명확하게 비권력주의를 지향하는 답변을 제시하였다. 남성성 대 여성성 항목의 경우, ChatGPT는 한글로 질문했을 때 더 명학한 여성성 답변을 보였으나, Clova X는 영어 질문에 더 명확한 여성성 답변을 보였다.

6. 결론

본 연구는 두 가지의 대형 언어 모델을 활용하여 모델들이 학습 시 구축된 환경, 질문의 언어, 질문 내용에 따라 답변의 차이가 존재하는지, 그 답변이 모델 학습 환경에 영향을 받은 것인지 구체적으로 살펴보고자 하였다. 이러한 연구는 대형 언어 모델이 인간의 가치 체계를 얼마나 잘 이해하고 반영할 수 있는지와 관련하여 중요한 질문에 대한 답을 제공한다.

이번 연구를 통해 우리는 대형 언어 모델들이 답변에 있어 생각보다 다양한 요소에 영향을 받지 않음을 확인할 수 있었다. 결과적으로, 모델 학습 시 구축된 환경은 답변에 큰 영향을

미치지 않는 것으로 나타났다. 만약 각 모델이 학습된 데이터셋의 특성과 그 국가나 문화에 따른 편향을 반영하게 되면 모델별로 동일 질문에 대해 생성된 답변들이 상반된 입장을 취할 수 있다는 점에서 이를 확인하는 것은 중요하다. 반면, 질문의 언어는 답변에 차이를 만들어 내는 요인 중 하나였다. 한국어와 영어로 동일한 질문을 제공했을 때, 모델의 답변이 상이한 경향을 보였다. 이는 언어로 판단될 수 있는 문화적 특성과 더불어 모델이 학습한 데이터셋의 언어적 특성을 고려해야 함을 시사한다.

대형 언어 모델을 활용한 자연어 이해와 생성에 있어서는 모델의 학습 환경과 데이터셋의 다양성이 매우 중요하다는 점을 강조하고자 한다. 각 모델이 가지고 있는 문화적 특성들에 따라 때로는 매우 다른 결과물을 생성해 낼 수 있기 때문이다. 또한, 모델의 답변이 언어와 문화적 편향을 반영할 수 있음을 고려하여, 이러한 편향을 극복하고 공정한 결과를 얻기 위한 노력이 필요하다.

본 연구는 대형 언어 모델들의 답변에 영향을 미치는 다양한 요인들을 살펴보았으나, 몇 가지 한계점이 존재한다. 먼저, 연구 대상 모델의 범위를 확장하여 더 많은 모델을 포함하는 것이 필요하다. 또한, 학습 데이터셋의 다양성과 국가별 문화 특성을 보다 정확히 반영하는 방법에 대한 연구가 필요하다. 본 연구에서는 영어와 한국어만을 사용하여 질문했으나, 나라별의 답변을 확인하는 작업을 추가시키고 싶다면 해당 국가의 고유 언어를 사용하여 질문해 보는 것이 타당하다. 더불어 대형 언어 모델은 복잡한 신경망 구조로 되어 있으며, 그 내부 동작을 완전히 이해하는 것은 쉽지 않다. 따라서 미래 연구에서는 더 심층적이고 체계적인 분석을 통해 모델의 작동 메커니즘을 더 잘 이해하는 것이 필요하다.

미래 연구에서는 다양한 언어와 문화를 고려한 대형 언어 모델의 개발과 활용에 대한 연구가 더욱 확대될 것으로 예상된다. 또한, 인간의 가치 및 편향을 잘 이해하고 반영하는 모델의 개발을 통해 보다 공정하고 효과적인 대화 및 의사소통이 이루어질 수 있을 것으로 기대된다. 이를 위해서는 대형 언어 모델들 간 문화적 특성 차이 중 차별이나 편향과 같은 부정적 요소들이 하루빨리 개선되어야 할 것이다.

참고문헌

Edmond, A., Dsouza, S., Kim, R., Schulz. J., Henrich, J., Shariff, A., Bonnefon, J-F., and Rahwan, I. The moral machine experiment. *Nature*, 563, no. 7729 (2018): 59-64.

Feng, S., Park, C.Y., Liu, Y., Tsvetkov, Y. From pretraining data to language models to downstream tasks: tracking the trails of political biases leading to unfair NLP models. *arXiv:2305.08283* (2023).

Hofstede, G.(2001). *Culture's consequences :comparing values, behaviors, institutions, and organizations across nations*(2nd ed). Thousand oaks: Sage publications.

Hofstede, G.(2010). The GLOBE debate: Back to relevance. *Journal of International Business Studies*, 41(8), 1339-1346.

J. Zhang, H. Feng, B. Liu, and D. Zhao, "Survey of technology in network security situation awareness," *Sensors*, Vol. 23, No. 5, p. 2608, 2023.

Khlaaf, H., Mishkin, P., Achiam, J., Krueger, G., & Brundage, M. (2022). A hazard analysis framework for code synthesis large language models. *arXiv preprint arXiv:2207.1415*

McKinsey Global Institute, 2023, The economic potential of generative AI: The next productivity frontier.

Zhao, Wayne Xin, et al. "A survey of large language models." *arXiv preprint arXiv:2303.18223* (2023).

김달훈. (2023년 9월 12일). "생성형 AI 활용에 세대차 뚜렷… Z세대는 70% 사용" 세일즈포스. *CIO KR*. https://www.ciokorea.com/news/306931

김진오. (2023년 6월 27일). 우리국민 61% "인공지능은 사회에 긍정적". *데이터솜*. https://www.datasom.co.kr/news/articleView.html?idxno=127278

유재연, 박기은, 서봉원. (2024). 소셜 시뮬레이션에서의 거대언어모델 활용: 언론자유지수 실험을 중심으로. *한국HCI학회 학술대회*, 103 - 108 (6page).

이위, 황경화, 최지애, 권오병. (2023). 거대언어모델의 차별문제 비교 연구. *지능정보연구*, 29(3), 125-144.

이지민, 이선영, 정남호, 구철모. (2016). 홉스테드 문화차원 이론을 적용한 국가별 한류동향과 인식차이에 관한 연구. *호텔관광연구*, 18(2), 21-40.

이진천. (2020). 편견도 학습하는 인공지능(AI). 설비저널, 49(5), 92-93.

이창섭, 이현정. (2019). 인공지능 혁신에 대한 기대와 불안 요인 및 영향 연구. *한국콘텐츠학회논문지*, 19(9), 37-46.

인공 지능 세계의 거대 언어 모델(LLM) 이해. n.d. *몽고DB*. https://www.mongodb.com/ko-kr/basics/large-language-models

차재호, 나은영. (1995). *세계의 문화와 조직*. 학지사. (Hofstede. 1991. *Culture and organizations: Software of the mind*. McGraw- Hill Companies.)

차재호, 나은영. (2014). *세계의 문화와 조직*. 학지사. (Hofstede and Minkov. 2010. *Cultures and Organizations: Software of the Mind*. McGraw-Hill, New York.)

최훈, 김진우. (2006). 불확실성 회피성향이 수용 후 행동에 미치는 영향: 모바일 인터넷 서비스를 중심으로. *경영정보학연구*, 16(3), 95-116.